

Aprendizaje híbrido de datos y física para pronósticos atmosféricos usando PINNs

Autor:

Lic. Fabricio Lopretto

Director:

Dra. Yanina García Skabar (Servicio Meteorológico Nacional)

Codirector:

Dr. Maximiliano Antonio Sacco (Servicio Meteorológico Nacional)

Esta planificación fue realizada en el curso de Gestión de proyectos entre el 04 de marzo de 2025 y el 18 de abril de 2025.

Índice

1. Descripción técnica-conceptual del proyecto a realizar	5
2. Identificación y análisis de los interesados	9
3. Propósito del proyecto	10
4. Alcance del proyecto	10
5. Supuestos del proyecto	11
6. Requerimientos	11
7. Historias de usuarios (<i>Product backlog</i>)	12
8. Entregables principales del proyecto	14
9. Desglose del trabajo en tareas	15
10. Diagrama de Activity On Node	16
11. Diagrama de Gantt	16
12. Presupuesto detallado del proyecto	18
13. Gestión de riesgos	18
14. Gestión de la calidad	21
15. Procesos de cierre	23

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	04 de marzo de 2025
1	Se completa hasta el punto 5 inclusive	17 de marzo de 2025
2	Se completa hasta el punto 9 inclusive	27 de marzo de 2025
3	Se completa hasta el punto 12 inclusive	02 de abril de 2025
4	Se completa el plan	08 de abril de 2025
5	Se ultiman detalles del plan	15 de abril de 2025

Acta de constitución del proyecto

Buenos Aires, 04 de marzo de 2025

Por medio de la presente se acuerda con el Lic. Fabricio Lopretto que su trabajo final de la Carrera de Especialización en Inteligencia Artificial se titulará “Aprendizaje híbrido de datos y física para pronósticos atmosféricos usando PINNs” y consistirá en el estudio de arquitecturas de redes neuronales destinadas al pronóstico atmosférico. El trabajo tendrá un presupuesto preliminar estimado de 610 horas y un costo estimado de \$ 7.208.000, con fecha de inicio el 04 de marzo de 2025 y fecha de presentación pública en noviembre de 2025.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Dr. Marcos Adolfo Saucedo
Servicio Meteorológico Nacional

Dra. Yanina García Skabar
Director del Trabajo Final

Dr. Maximiliano Antonio Sacco
Codirector del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

Este proyecto se desarrolla en el marco de la misión del Servicio Meteorológico Nacional (SMN), en particular se vincula con las actividades de la Dirección de Productos de Modelación Ambiental y Sensores Remotos, con el objetivo de desarrollar herramientas innovadoras para la predicción atmosférica en la región del sur de Sudamérica. En este contexto, el trabajo busca integrar técnicas avanzadas de redes neuronales con ecuaciones físicas fundamentales para la predicción meteorológica, específicamente para la evolución temporal de variables atmosféricas clave en niveles medios de la troposfera, tales como temperatura, presión, humedad y viento.

La propuesta de valor de este estudio radica en la creación de un modelo alternativo a los enfoques numéricos tradicionales basados en ecuaciones físicas, utilizando redes neuronales informadas por física (PINNs). Este enfoque no solo permite que el modelo aprenda de los datos de observación, sino que también integra las leyes fundamentales que rigen la dinámica atmosférica, representadas por el sistema de ecuaciones de Navier-Stokes. La innovación que se propone está en la combinación de esta integración física con capas de Fourier (FNO), lo que agrega un valor adicional a los modelos tradicionales y a las implementaciones previas en redes neuronales.

En los últimos años, los avances en inteligencia artificial y aprendizaje profundo han abierto nuevas posibilidades en la predicción meteorológica. Uno de los ejemplos más destacados en este sentido es el modelo FourCastNet, desarrollado por NVIDIA en colaboración con el Centro Europeo de Pronósticos Meteorológicos a Medio Plazo (ECMWF), que utiliza redes neuronales con capas de Fourier para generar inferencias de variables meteorológicas a partir de datos de reanálisis. Este modelo, junto con otros, representa uno de los primeros pasos hacia la implementación operativa de modelos meteorológicos basados en redes neuronales, superando en algunos casos las limitaciones de los métodos numéricos tradicionales.

A pesar de estos avances, la mayoría de los modelos de inteligencia artificial actuales se basan en enfoques puramente basados en datos, sin integrar explícitamente las leyes fundamentales de la física que rigen los fenómenos meteorológicos. El trabajo propuesto busca llenar este vacío al incorporar las ecuaciones de Navier-Stokes dentro de la red neuronal, lo que permite que el modelo no solo aprenda de los datos de observación, sino que también respete las leyes físicas que determinan el comportamiento de la atmósfera.

Los modelos tradicionales presentan dos problemas fundamentales que generan incertidumbre en los pronósticos: por un lado, la imposibilidad de conocer completamente las condiciones iniciales y de borde debido a la limitada disponibilidad de datos; y por otro, la incapacidad de representar con precisión todos los procesos físicos, especialmente considerando las interacciones no lineales entre las distintas escalas. En la figura 1 se muestra un ejemplo de retícula utilizado en los modelos tradicionales para resolver las ecuaciones que describen los procesos que se desarrollan en la atmósfera.

La solución propuesta consiste en el uso de redes neuronales informadas por física (PINNs), que permiten que un modelo de aprendizaje profundo respete las ecuaciones de la dinámica atmosférica. Este modelo aprenderá la evolución temporal de las variables atmosféricas en la región de interés, utilizando datos de reanálisis para los horarios 00Z, 06Z, 12Z y 18Z de cada día, en el nivel de 500 hPa (5000 m.s.n.m.). Al integrar las ecuaciones de Navier-Stokes dentro del aprendizaje de la red neuronal, se garantiza que las predicciones sean físicamente consistentes, lo que mejora la confiabilidad de los pronósticos meteorológicos.

Weather forecast modeling

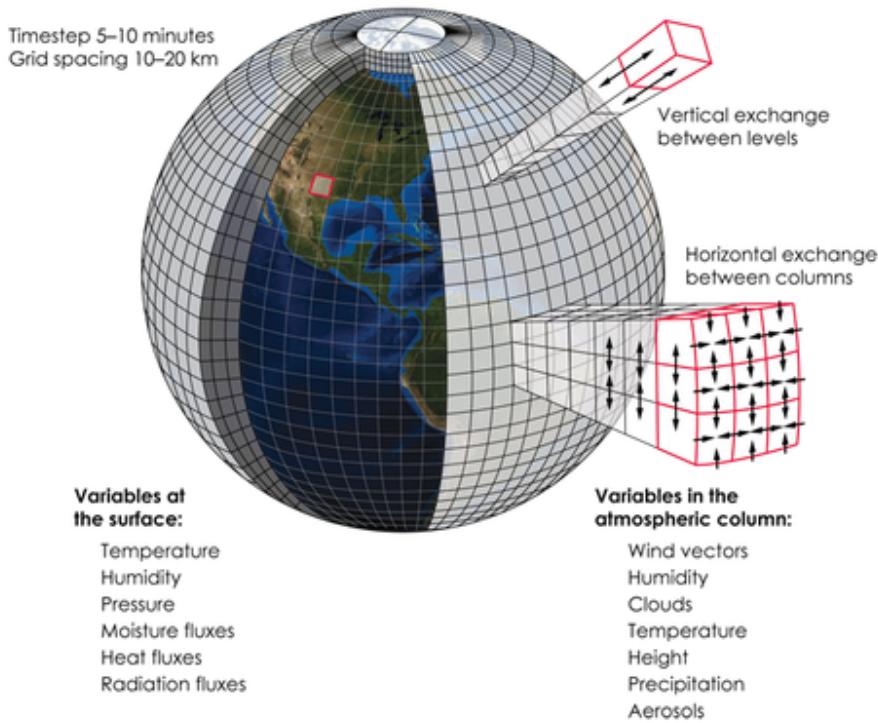


Figura 1. Ejemplo de una retícula usada para el modelado numérico de la atmósfera, imagen de The COMET® Program.

El valor agregado de este trabajo radica en la combinación de PINNs con capas de Fourier (FNO), lo que permite que el modelo aprenda no solo a partir de los datos de reanálisis meteorológicos, sino que también integre patrones y características a distintas escalas de frecuencia, mejorando la capacidad de capturar la dinámica compleja de la atmósfera.

La solución propuesta consiste en un modelo basado en redes neuronales que aprende la evolución temporal de variables atmosféricas clave (temperatura, humedad, viento, etc.) en la troposfera media. Este modelo utilizará datos de reanálisis, los cuales se basan en estimaciones previas generadas por modelos meteorológicos ajustados con observaciones provenientes de satélites, estaciones meteorológicas, radiosondas, entre otros. El objetivo primario de los reanálisis es el de proveer una estimación del estado de la atmósfera en una retícula regular. En este trabajo se utilizarán datos de *European Centre for Medium-Range Weather Forecasts Re-Analysis* de quinta generación (ERA-5), incorporándolos a la red neuronal propuesta.

El modelo se implementará en una retícula tridimensional, como la mostrada en la figura 2, para el nivel de 500 hPa. Las predicciones serán generadas para los horarios 00Z, 06Z, 12Z y 18Z de cada día. Una vez entrenado, el modelo podrá realizar predicciones de las variables atmosféricas para la región de Sudamérica.

Este modelo alternativo a los enfoques numéricos tradicionales de predicción atmosférica representa un paso importante hacia la mejora de la calidad de los pronósticos meteorológicos regionales, y tiene el potencial de ser una herramienta valiosa para los pronosticadores del SMN.

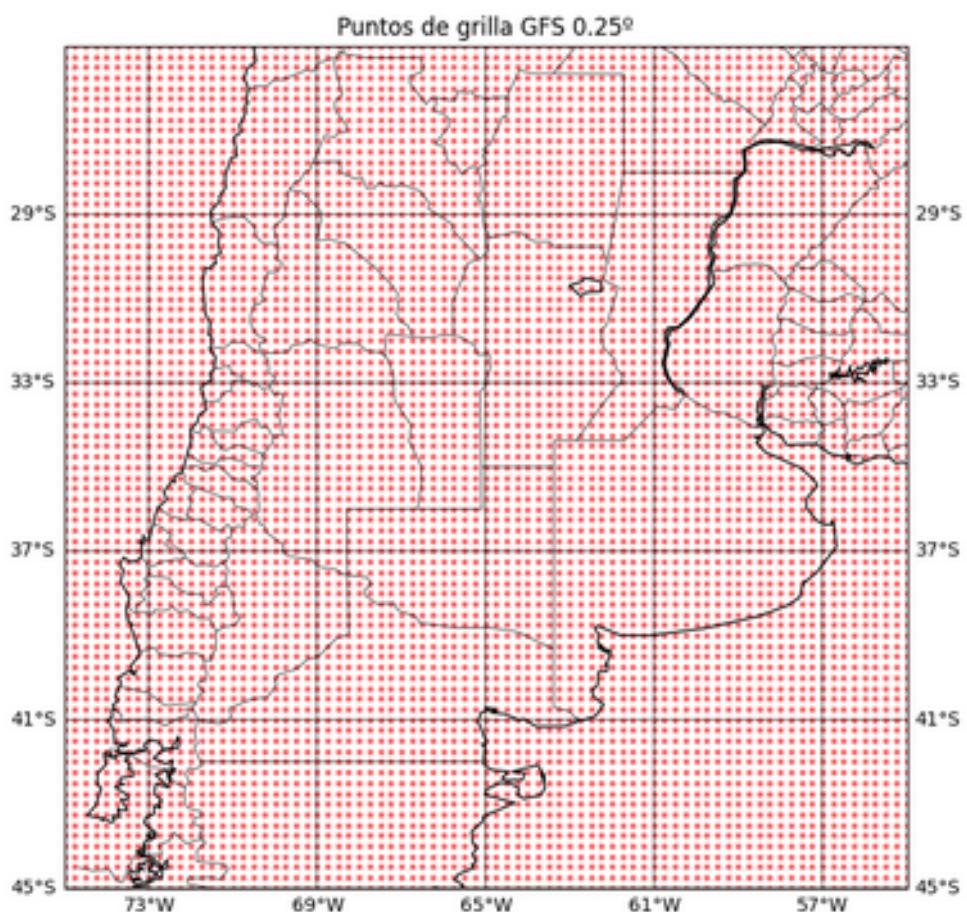


Figura 2. Parte central del dominio espacial de implementación del modelo propuesto basado en PINN, basado en la grilla de puntos del modelo numérico meteorológico *European Centre for Medium-Range Weather Forecasts* (ECMWF) con una resolución de 0,25°.

En comparación con modelos existentes como FourCastNet, la propuesta presentada va más allá al incorporar explícitamente las ecuaciones físicas (Navier-Stokes) en el proceso de entrenamiento de la red neuronal, lo que garantiza que las inferencias sean no solo basadas en los datos, sino también en las leyes que rigen el comportamiento de la atmósfera. Además, al incorporar capas de FNO, se añade un nivel adicional de sofisticación al proceso de aprendizaje, lo que puede mejorar la precisión y la robustez del modelo.

Actualmente, el modelo está en una fase de desarrollo avanzada, con las arquitecturas empleadas definidas, cuyos diagramas de bloques se muestran en la figura 3, y los conjuntos de entrenamiento establecidos. Sin embargo, es necesario avanzar en la optimización de hiperparámetros, en la validación y prueba del modelo, para asegurar su efectividad y confiabilidad en un entorno operativo.

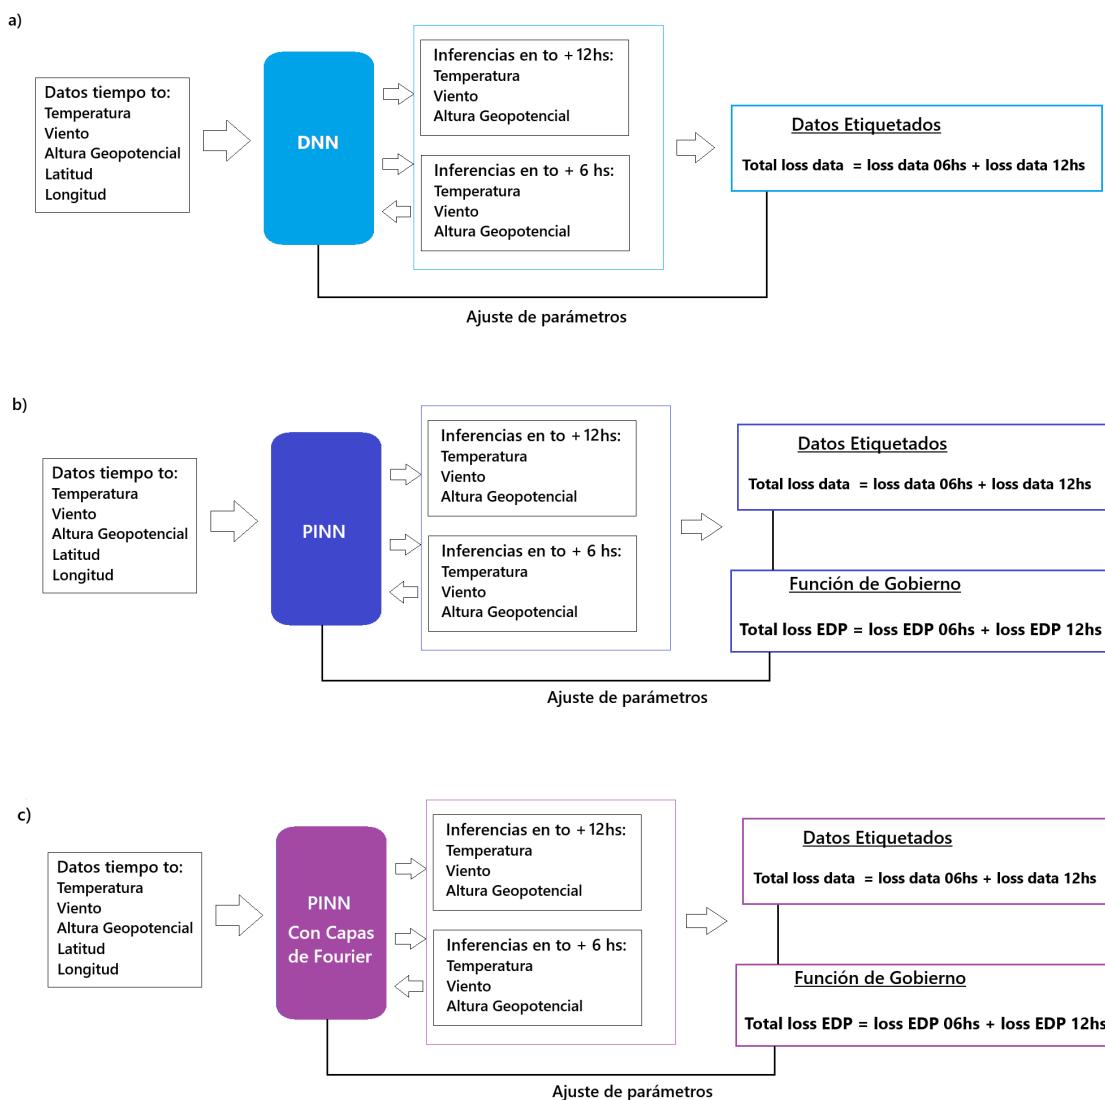


Figura 3. Diagrama de bloques de las arquitecturas empleadas, siendo a) red neuronal profunda (DNN), b) red neuronal informada por física (PINN), y c) red neuronal informada por física con capas de Fourier (PINN con FNO).

El cliente de este proyecto es el centro regional de pronósticos del SMN, cuya misión es proporcionar información y pronósticos meteorológicos para proteger a la población y contribuir al desarrollo sostenible. El SMN valora las herramientas que pueden mejorar la precisión y eficiencia de sus pronósticos, y está interesado en explorar nuevas tecnologías que complementen y mejoren los modelos numéricos tradicionales.

La innovación del proyecto radica en la combinación de técnicas avanzadas de redes neuronales con el respeto por las leyes fundamentales de la física, lo que permite generar predicciones físicamente consistentes. Además, al integrar capas de Fourier en el proceso de aprendizaje, el modelo tiene el potencial de capturar patrones más complejos y mejorar la capacidad predictiva de los sistemas actuales.

2. Identificación y análisis de los interesados

Rol	Nombre y Apellido	Organización	Puesto
Cliente	Dr. Marcos Adolfo Saucedo	SMN	Director CPR
Responsable	Lic. Fabricio Lopretto	SMN - FIUBA	Alumno
1er Orientador	Dra. Yanina García Skabar	SMN	Directora trabajo final
2do Orientador	Dr. Maximiliano Antonio Sacco	SMN	Codirector trabajo final
Usuario final	Centro Regional de Pronósticos	SMN	Pronosticadores e investigadores

- Cliente: trabajando en las áreas de pronóstico del tiempo e investigación, su labor abarca desde el impacto de errores en sistemas de asimilación de datos hasta el desarrollo de umbrales meteorológicos y herramientas para la gestión del riesgo por eventos extremos. Actualmente, se desempeña como director de pronósticos del tiempo y avisos en el SMN, lidera la emisión de pronósticos y alertas meteorológicas operativas para la sociedad, combinando su expertise científica con aplicaciones directas en la toma de decisiones y la gestión del riesgo.
- 1er Orientador: cuenta con una sólida trayectoria en modelado numérico de la atmósfera y asimilación de datos, aplicados al pronóstico de eventos meteorológicos de alto impacto. Su experiencia liderando la implementación de sistemas de pronóstico en alta resolución y su participación en proyectos internacionales demuestran su capacidad para guiar investigaciones innovadoras. Además, su trabajo en organismos como el SMN y la Organización Meteorológica Mundial (OMM) la posiciona en un entorno de colaboración científica de alto nivel, brindando acceso a conocimientos avanzados y redes de expertos.
- 2do Orientador: es un investigador con una sólida trayectoria en asimilación de datos, cuantificación de incertidumbre y modelado numérico del clima, combinando enfoques tradicionales con técnicas de aprendizaje automático. Su experiencia en proyectos internacionales, múltiples publicaciones en revistas de alto impacto y presentaciones en congresos lo posicionan como un excelente codirector de tesis. Además, su trabajo interdisciplinario entre meteorología, computación y *machine learning* le permite aportar

una visión integral y actualizada, guiando investigaciones innovadoras y relevantes en la frontera del conocimiento.

- Usuario Final: Analistas e Investigadores de aplicación científica.

3. Propósito del proyecto

El propósito de este proyecto es indagar en el desarrollo de un modelo de predicción atmosférica innovador que combine el aprendizaje automático con el conocimiento físico de la dinámica atmosférica, con el fin de mejorar la precisión y confiabilidad de los pronósticos meteorológicos en la región de Sudamérica. Se busca superar las limitaciones de los modelos numéricos tradicionales, que requieren altos costos computacionales, y de los enfoques basados únicamente en datos, que pueden carecer de consistencia física. Mediante el uso de PINNs y capas FNO, el objetivo es generar un modelo capaz de aprender la evolución temporal de variables atmosféricas clave respetando las ecuaciones de Navier-Stokes, lo que permitirá proporcionar inferencias más realistas y físicamente consistentes. Con esta iniciativa, se espera aportar una herramienta valiosa para el SMN, fortaleciendo sus capacidades operativas en la predicción del tiempo y contribuyendo a la toma de decisiones en sectores estratégicos como la gestión de emergencias, la agricultura y el transporte.

4. Alcance del proyecto

El proyecto incluye:

- Generación de arquitecturas.
 - Red neuronal solo informada por datos (DNN).
 - Red neuronal informadas por física, basada en PINN.
 - Red neuronal informadas por física, basada en PINN con capas FNO.
- Colección de datos de reanálisis con variables meteorológicas obtenidos desde el conjunto de datos ERA-5.
- Optimización de hiperparámetros.
- Prueba de modelos propuestos.
- Comparación de pronósticos elaborados por los modelos.

El proyecto no incluye:

- Escalado de los modelos a dominio global y tridimensional.
- Implementación de condiciones de borde.
- Puesta en operatividad.
 - Puesta en marcha en servidores operativos.
 - Elaboración y ejecución de plan de mantenimiento.
 - Reentrenado periódico de los modelos elaborados.
- Métodos de calibración.

5. Supuestos del proyecto

Para el desarrollo del presente proyecto se suponen las siguientes consideraciones:

- La disponibilidad de datos históricos de reanálisis de al menos cinco años para entrenamiento, validación y evaluación de los modelos de inteligencia artificial propuestos.
- Se tendrá acceso a plataformas de cómputo en la nube como *Google Colaboratory* o similares. Se asume que, a lo largo de la duración de este proyecto, estas plataformas continuarán teniendo una versión de disponibilidad gratuita.
- Los recursos materiales, como equipos de cómputo y servidores, están disponibles y son suficientes para llevar a cabo las tareas que demanda el proyecto en tiempo y forma.
- La disponibilidad de tiempo del autor del proyecto será similar a lo largo de toda la duración del mismo. La aparición de imprevistos que impidan la normal dedicación será poco frecuente.
- El acceso a la literatura científica relacionada al tema será irrestricto. Existe gran cantidad de trabajos publicados en repositorios de acceso abierto (tipo arXiv o similares).

6. Requerimientos

A continuación, se enumeran los requerimientos que el presente proyecto deberá satisfacer:

1. Requerimientos funcionales:

- 1.1. Arquitectura sin aprendizaje de física.
- 1.2. Arquitectura con aprendizaje de física, sin capas de Fourier.
- 1.3. Arquitectura con aprendizaje de física, con capas de Fourier.

2. Requerimientos del usuario:

- 2.1. El sistema debe generar inferencias a venticuatro horas, con pasos de seis horas, en menos de diez minutos.
- 2.2. Simplificaciones asumidas en la implementación de las ecuaciones diferenciales de pronóstico utilizadas.
- 2.3. Publicación de los recursos computacionales empleados y los tiempos de ejecución acusados durante el entrenamiento de cada modelo elaborado.
- 2.4. Publicación de los hiperparámetros y de los métodos de optimización utilizados para hallarlos.
- 2.5. Las inferencias se deben presentar en un formato gráfico similar al implementado en las predicciones del modelo numérico utilizado en el organismo.

3. Requerimientos asociados con el estudio del estado del arte:

- 3.1. Estudio de al menos 3 artículos sobre los fundamentos de PINN, PINO y la implementación de capas de Fourier.
- 3.2. Estudio de al menos 3 artículos para conocer el desarrollo actual de modelos de pronóstico meteorológico basado en redes neuronales.

4. Requerimiento de testing:

- 4.1. El sistema debe generar inferencias físicamente consistentes.
- 4.2. Los modelos planteados deben arrojar valores del mismo orden de magnitud de MSE con respecto al modelo físico de referencia *Weather Research and Forecasting* (WRF-SMN), para ser considerados como herramientas de pronóstico utilizables a futuro.

5. Requerimientos de documentación:

- 5.1. Confección del informe de avance.
- 5.2. Elaboración de la memoria final.

7. Historias de usuarios (*Product backlog*)

Se ha establecido un método para calcular los puntos de historia de usuario basado en tres criterios fundamentales: dificultad, complejidad y riesgo.

- Dificultad: es la medición de la carga laboral o el tiempo que implica la realización de una tarea del proyecto, teniendo en cuenta no solo el trabajo directamente relacionado con la historia de usuario, sino también su impacto en la duración y carga de trabajo del resto de las tareas del proyecto.
- Complejidad: es la valoración de la dificultad que conlleva la ejecución de una tarea del proyecto, tanto en términos de la sofisticación del trabajo como de los conocimientos y habilidades requeridos para llevarla a cabo. También se considera la dificultad en conseguir los recursos necesarios para su ejecución.
- Riesgo: es la evaluación de la probabilidad de que una tarea del proyecto presente problemas o desvíos en su cumplimiento, así como el impacto que dichos problemas podrían tener en otras tareas del proyecto.

Para la evaluación de historias se utilizará una escala de puntuación basada en la serie de Fibonacci. Se evaluarán las historias en base a los tres criterios mencionados.

El puntaje total de cada historia se calculará como la suma de los puntajes obtenidos en cada uno de los criterios evaluados. Luego, se aproximarán al número de la serie de Fibonacci inmediatamente superior al resultado de la suma.

Esta metodología de evaluación asegura que cada criterio tenga una importancia relativa en la evaluación final y que las historias más destacadas obtengan una puntuación más alta. Además, la utilización de la serie de Fibonacci para la escala de puntuación permite una mayor precisión en la evaluación, evitando la ambigüedad en la asignación de calificaciones intermedias.

Épica 1: Desarrollo y entrenamiento del modelo

Historia 1: Entrenamiento del modelo con datos de reanálisis

- Quién: Investigador en meteorología.
- Qué: Entrenar una red neuronal con datos de reanálisis del ERA-5.

- Para qué: Mejorar la precisión en el pronóstico meteorológico y analizar su rendimiento.
- Dificultad: 3, Complejidad: 3, Incertidumbre: 2
- Story Points: 8

Historia 2: Evaluación de la interpretabilidad del modelo

- Quién: Investigador en meteorología.
- Qué: Analizar la interpretabilidad del modelo y su capacidad de explicación.
- Para qué: Asegurar que los pronosticadores comprendan los resultados generados.
- Dificultad: 2, Complejidad: 2, Incertidumbre: 1
- Story Points: 5

Épica 2: Implementación operativa

Historia 3: Implementación del modelo en un entorno operativo

- Quién: Desarrollador de software.
- Qué: Integrar el modelo en el sistema del SMN.
- Para qué: Permitir su uso por parte de pronosticadores y otros usuarios.
- Dificultad: 5, Complejidad: 5, Incertidumbre: 3
- Story Points: 13

Historia 4: Creación de interfaz para visualización de pronósticos

- Quién: Desarrollador de software.
- Qué: Diseñar una interfaz amigable para visualizar los pronósticos generados por la red neuronal.
- Para qué: Facilitar la interpretación de los resultados por parte de los usuarios finales.
- Dificultad: 3, Complejidad: 3, Incertidumbre: 2
- Story Points: 8

Épica 3: Optimización y escalado

Historia 5: Escalado del modelo a mayor resolución y complejidad

- Quién: Desarrollador de software.
- Qué: Aumentar la resolución espacial y temporal del modelo.
- Para qué: Mejorar la calidad del pronóstico en diferentes escalas.

- Dificultad: 5, Complejidad: 5, Incertidumbre: 3
- Story Points: 13

Historia 6: Optimización del tiempo de cálculo del modelo

- Quién: Desarrollador de software.
- Qué: Mejorar la eficiencia computacional del modelo.
- Para qué: Reducir los tiempos de ejecución y permitir su uso en operación.
- Dificultad: 3, Complejidad: 3, Incertidumbre: 2
- Story Points: 8

Épica 4: Mantenimiento y soporte

Historia 7: Implementación de monitoreo y detección de fallas del modelo

- Quién: Equipo de soporte informático.
- Qué: Desarrollar herramientas para monitorear el rendimiento del modelo.
- Para qué: Detectar y corregir errores en tiempo real.
- Dificultad: 3, Complejidad: 3, Incertidumbre: 2
- Story Points: 8

Historia 8: Documentación del modelo y su implementación

- Quién: Desarrollador de software / Investigador.
- Qué: Crear una guía detallada sobre el funcionamiento del modelo y su integración.
- Para qué: Facilitar su uso, mantenimiento y futuras mejoras.
- Dificultad: 2, Complejidad: 2, Incertidumbre: 1
- Story Points: 5

8. Entregables principales del proyecto

Los entregables del proyecto son:

- Revisión bibliográfica.
- Conjuntos de datos de reanálisis utilizados.
- Arquitecturas de modelos diseñados.
- Modelos entrenados y optimizados.

- Código fuente.
- Resultados.
- Memoria del trabajo final.

9. Desglose del trabajo en tareas

1. Planificación preliminar (45 h)

- 1.1. Reunión con orientadores para discusión de propuesta de trabajo (2 h).
- 1.2. Elaboración de experimentos preliminares (40 h).
- 1.3. Redacción propuesta de proyecto final (3 h).

2. Estudio del estado del arte (20 h)

- 2.1. Revisión de artículos sobre PINN, PINO y capas de Fourier (10 h).
- 2.2. Análisis de desarrollos actuales en redes neuronales para pronóstico meteorológico (10 h).

3. Obtención y procesamiento de datos (30 h)

- 3.1. Adquisición de datos de reanálisis (10 h).
- 3.2. Generación de conjuntos de entrenamiento, validación y prueba (10 h).
- 3.3. Implementación de simplificaciones en las ecuaciones diferenciales de pronóstico (10 h).

4. Diseño de arquitecturas de modelos (160 h)

- 4.1. Desarrollo de la arquitectura sin aprendizaje de física (20 h).
- 4.2. Desarrollo de la arquitectura con aprendizaje de física sin capas de Fourier (30 h).
- 4.3. Desarrollo de la arquitectura con aprendizaje de física con capas de Fourier (40 h).
- 4.4. Implementación de métodos de normalización (20 h).
- 4.5. Implementación de términos en la función de pérdida (20 h).
- 4.6. Prueba de códigos y *debugging* (30 h).

5. Entrenamiento, validación y optimización de modelos (200 h)

- 5.1. Implementación de método *random search* (40 h).
- 5.2. Implementación de método *grid search* (40 h).
- 5.3. Implementación de *cross validation* (40 h).
- 5.4. Entrenamiento de cada modelo (40 h).
- 5.5. Evaluación de desempeño (30 h).
- 5.6. Elaboración de figuras de curvas de aprendizaje (10 h).

6. Testing (45 h)

- 6.1. Generación de inferencias con horizonte de siete días en intervalos de seis horas (5 h).
- 6.2. Comparación de resultados con modelos numéricos tradicionales (40 h).

7. Documentación del proyecto (110 h)

- 7.1. Elaboración del informe de avance (20 h).
- 7.2. Redacción preliminar de la memoria escrita (40 h).
- 7.3. Revisión, corrección y edición de la memoria preliminar (20 h).
- 7.4. Preparación de la versión final de la memoria escrita (10 h).
- 7.5. Preparación de la presentación pública del trabajo final (20 h).

Cantidad total de horas: 610.

10. Diagrama de Activity On Node

La figura 4 muestra el diagrama de *Activity on Node* (AoN) de las actividades listadas en la sección 9, indicando los hitos de inicio y fin del proyecto, la dependencia de tareas, y el camino crítico. La duración de cada actividad está expresada en horas.

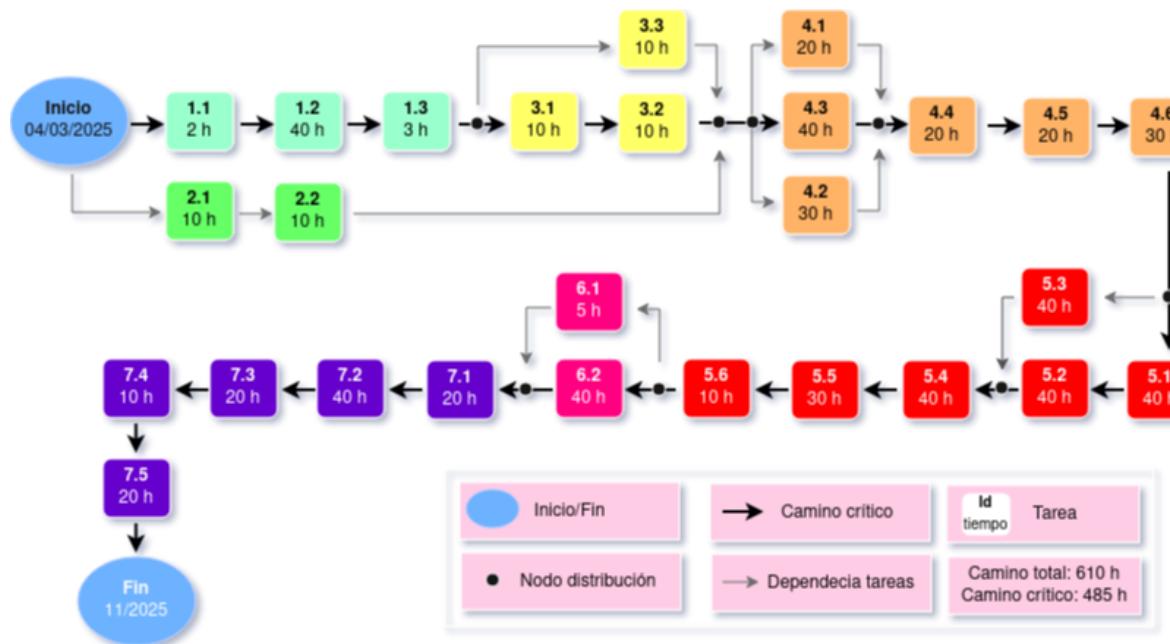


Figura 4. Diagrama de *Activity on Node*. Imagen realizada con draw.io.

11. Diagrama de Gantt

La figura 5 muestra el diagrama de Gantt de las tareas listadas en la sección 9. A los fines de ajustar el diagrama a una sola página, la descripción de algunas actividades fue mostrada de forma abreviada. Para ver el contenido completo del texto de cada una de las actividades ver la sección 9.

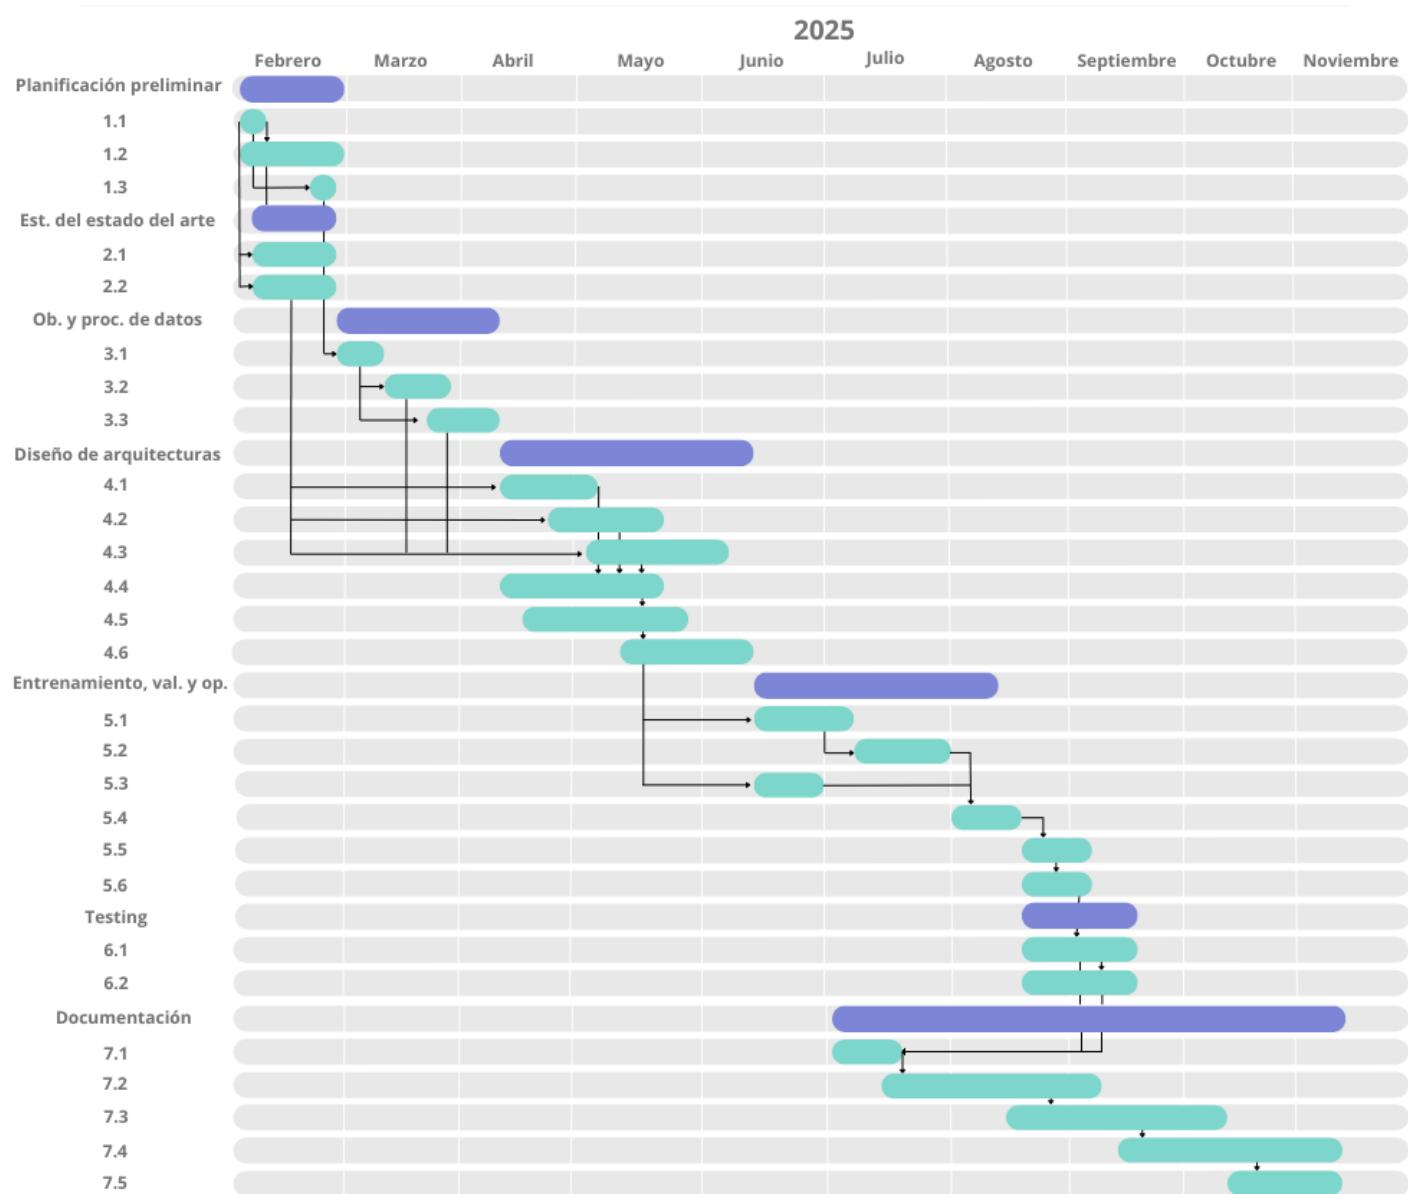


Figura 5. Diagrama de Gantt (apaisado).

12. Presupuesto detallado del proyecto

Se debe destacar que en este proyecto se utilizarán datos de libre acceso provistos por ECMWF.

En el cuadro 1 muestra el presupuesto del proyecto, con los valores monetarios expresados en pesos argentinos (1100 ARS es igual a 1 USD oficial).

Cuadro 1. Presupuesto del proyecto.

COSTOS DIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
Horas del responsable	610 h	\$ 9000	\$ 5490000
Reuniones de coordinación y planificación	10	\$ 1000	\$ 10000
GPUs para entrenamiento de modelo	1	\$ 10000	\$ 10000
Costo anual 100 GB en la nube	1	\$ 20000	\$ 20000
SUBTOTAL			\$ 5530000
COSTOS INDIRECTOS			
Descripción	Cantidad	Valor unitario	Valor total
Costo energía eléctrica	10 meses	\$ 10000	\$ 100000
Costo de internet	10 meses	\$ 40000	\$ 400000
Presentaciones en congresos	1	\$ 70000	\$ 70000
Material de librería	1	\$ 2000	\$ 2000
Otros, estipulados como %20 del costo directo	1	\$ 1106000	\$ 1106000
SUBTOTAL			\$ 1678000
TOTAL			\$ 7208000

13. Gestión de riesgos

Se enumeran los riesgos identificados y se estiman sus consecuencias. Para esto, a cada riesgo se le asigna un número que representa su severidad (S) y otro que representa su tasa de ocurrencia (O). La escala de números a utilizar varía de 1 a 10, siendo este último el valor que representa el riesgo más severo o con mayor tasa de ocurrencia, según corresponda. Finalmente, S y O se multiplican, dando como resultado el valor de Número de Prioridad de Riesgo (RPN, por sus siglas en inglés). Los valores de RPN obtenidos se comparan con un valor umbral establecido. En caso de que el RPN sea mayor al umbral, se prevé un plan de contingencia y se recalcula el valor de RPN, debiéndose lograr un número menor al umbral.

Riesgo 1: fallo en la adquisición de datos de reanálisis.

- Severidad (S): 8.
Si no es posible obtener los datos de reanálisis necesarios para entrenar los modelos de inteligencia artificial planteados, el proyecto no podrá avanzar y se retrasará significativamente.
- Probabilidad de ocurrencia (O): 2.
Existe un bajo riesgo de que los datos de reanálisis no estén disponibles, dado que las fuentes gozan de confiabilidad.

Riesgo 2: artículos científicos de acceso restringido.

- Severidad (S): 3.
Existe una gran disponibilidad de artículos en la web sobre la temática que son de acceso gratuito.
- Ocurrencia (O): 8.
Es frecuente encontrar esta clase de limitaciones debido a las licencias impuestas por las revistas científicas donde se publican.

Riesgo 3: no contar con capacidad de cómputo suficiente.

- Severidad (S): 8.
Si no se cuenta con los recursos idóneos, las tareas se volverían más imprácticas y consumirían mayor tiempo del estimado.
- Ocurrencia (O): 2.
Es posible que a la hora de realizar el entrenamiento y optimización de hiperparámetros, se presente la necesidad de recursos computacionales por encima de lo estándar. El SMN cuenta con la infraestructura para solventar la demanda de cómputo mencionada.

Riesgo 4: cambios en los requerimientos del área operativa.

- Severidad (S): 7.
El área de pronóstico podría modificar los requerimientos (resolución temporal o espacial, variables clave), generando incompatibilidades con los modelos ya entrenados o necesidad de reentrenamiento.
- Ocurrencia (O): 3.
Los cambios de esquema de trabajo en las áreas operativas son de largo plazo dado los períodos de aprobación, prueba y validación que requieren antes de ser implementados en la elaboración de productos con impacto en la sociedad.

Riesgo 5: cambio de las autoridades gubernamentales.

- Severidad (S): 7.
Puede derivar en una redefinición de prioridades institucionales o en la reasignación de recursos. Si bien el proyecto puede continuar bajo nuevas gestiones, existe el riesgo de que se suspenda, se limite su aplicación operativa o pierda apoyo estratégico.
- Ocurrencia (O): 4.
Los cambios en autoridades gubernamentales son eventos relativamente frecuentes en un esquema democrático como el de Argentina. Dichos cambios no necesariamente afectan a un proyecto específico, esto dependerá de múltiples factores, como el grado de institucionalización del mismo, entre otros.

En el cuadro 2 se sintetiza la información de la gestión de riesgos (El RPN se calcula como $RPN=SxO$).

Se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a 20.

Nota: los valores marcados con (*) en la tabla corresponden luego de haber aplicado la mitigación.

Cuadro 2. Gestión de riesgo del proyecto.

Riesgo	S	O	RPN	S*	O*	RPN*
1	8	2	16	-	-	-
2	3	8	24	2	4	8
3	8	2	16	-	-	-
4	7	3	21	5	2	10
5	7	4	28	4	4	16

A continuación se presentan los planes de mitigación en los riesgos que originalmente excedían el RPN máximo establecido:

a) Plan de mitigación para Riesgo 2:

Se busca mitigar el impacto de las restricciones de acceso a artículos científicos, para ello se propone implementar una serie de acciones. Entre ellas:

- Priorizar la búsqueda en repositorios de acceso abierto (Open Access) y bases de datos científicas gratuitas, como Scielo, Redalyc, DOAJ o arXiv.
- Establecer convenios o solicitar acceso institucional a bibliotecas académicas a través del SMN o universidades colaboradoras.
- Contactar directamente a autores para solicitar copias de artículos mediante plataformas como ResearchGate o por correo electrónico.
- Explorar herramientas legales como el préstamo interbibliotecario o el uso de licencias compartidas dentro de redes académicas.

Estas estrategias aumentan las posibilidades de obtener la bibliografía requerida sin vulnerar derechos de autor, disminuyendo la frecuencia y el impacto del problema.

- Severidad (S*): 2. La disponibilidad de alternativas legales y gratuitas reduce aún más el impacto potencial sobre el desarrollo del proyecto.
- Ocurrencia (O*): 4. Al aplicar de forma sistemática estas estrategias, se reduce notablemente la frecuencia con la que el equipo se enfrenta a barreras de acceso.

b) Plan de mitigación para Riesgo 4:

La reducción del impacto debido a posibles cambios en los requerimientos del área operativa, se puede alcanzar proponiendo las siguientes consideraciones:

- Establecer canales de comunicación frecuentes y formales con el área operativa para anticipar posibles modificaciones en los requerimientos.
- Involucrar al equipo operativo en etapas clave del desarrollo del proyecto, especialmente durante el diseño de productos y la selección de variables y resoluciones.
- Documentar los procesos de entrenamiento y validación de modelos, de modo que la adaptación a nuevos requerimientos pueda realizarse con mayor eficiencia.

- Desarrollar prototipos escalables o modularizados que permitan actualizaciones parciales.

Estas acciones buscan reducir tanto la severidad del impacto como la frecuencia con la que estos cambios afectan negativamente al proyecto.

- Severidad (S*): 5. La mayor flexibilidad de los modelos y la coordinación temprana con el área operativa disminuyen el impacto que tendría un eventual cambio de requerimientos.
- Ocurrencia (O*): 2. La detección temprana de cambios en planificación, gracias a la mejora en la comunicación y participación conjunta, reduce la probabilidad de que los requerimientos cambien de forma inesperada.

c) Plan de mitigación para Riesgo 5:

Minimizar el impacto por cambios en las autoridades gubernamentales, se lograr a través de un conjunto de acciones orientadas a fortalecer la resiliencia institucional del proyecto. Estas incluyen:

- Institucionalizar el proyecto dentro del SMN.
- Documentar adecuadamente los procesos, avances y resultados.
- Comunicar públicamente los beneficios operativos y estratégicos del proyecto garantizar respaldo técnico y externo.
- Preparar material de transición destinado a nuevas autoridades, de forma que se facilite su comprensión y continuidad.

Una vez implementadas estas medidas, se espera una reducción de la severidad.

- Severidad (S*): 4. La institucionalización y visibilización del proyecto dentro del SMN mitigan el impacto potencial de una eventual discontinuidad política.
- Ocurrencia (O*): 4. El respaldo técnico y la preparación para la transición aumentan las chances de que el proyecto sea sostenido pese a cambios institucionales.

14. Gestión de la calidad

A continuación, se enumeran los requerimientos del proyecto y su correspondiente procedimiento de verificación y validación.

- Req #1: Diseño de arquitectura con aprendizaje de física, con capas de Fourier.
 - Verificación: Revisar el código fuente para confirmar la implementación correcta de capas de Fourier y la incorporación de términos físicos (ecuaciones diferenciales). Evaluar que la estructura respete el diseño propuesto.

- Validación: Mostrar al cliente inferencias generadas por esta arquitectura y compararlas con resultados esperados en variables meteorológicas clave. El cliente debe confirmar que los resultados son físicamente coherentes y comparables al modelo tradicional.
- Req #2: El sistema debe generar inferencias a venticuatro horas, con pasos de seis horas, en menos de diez minutos.
 - Verificación: Ejecutar pruebas temporales controladas del sistema para medir la duración real del proceso de inferencia sobre el dominio de interés y asegurar que no supere los 10 minutos.
 - Validación: El cliente realiza una prueba práctica con un conjunto de entrada real y constata que el sistema entrega las salidas completas (24 h, cada 6 h) dentro del tiempo esperado.
- Req #3: El sistema debe generar inferencias físicamente consistentes.
 - Verificación: Analizar internamente las salidas del modelo (gradientes, coeficientes, simplificaciones, entre otros) y chequear que no violen principios físicos fundamentales. Aplicar métricas de consistencia física.
 - Validación: Presentar al cliente salidas gráficas (como campos de presión, temperatura, viento, etc.) para que especialistas del área verifiquen que no se observan comportamientos físicamente imposibles.
- Req #4: Los modelos planteados deben arrojar valores del mismo orden de magnitud de MSE que el modelo físico de referencia WRF-SMN.
 - Verificación: Calcular el MSE de los modelos de IA planteados frente un conjunto de referencia, y compararlo con el MSE del modelo WRF-SMN sobre el mismo conjunto. Confirmar que están en el mismo orden.
 - Validación: Mostrar gráficamente las comparaciones de errores (tablas, curvas de error) al cliente, y obtener su conformidad de que el desempeño es suficientemente cercano al estándar actual.
- Req #5: Publicación de los recursos computacionales empleados y los tiempos de ejecución durante el entrenamiento de cada modelo elaborado.
 - Verificación: Confirmar que en los reportes de entrenamiento figuran los recursos (tipo de GPU/CPU, RAM, etc.) y los tiempos por época y totales de entrenamiento.
 - Validación: El cliente revisa los informes entregados (en PDF o documento técnico) y confirma que la información es clara, completa y útil para reproducibilidad.
- Req #6: Publicación de los hiperparámetros y de los métodos de optimización utilizados para hallarlos.
 - Verificación: Comprobar en el código todos los hiperparámetros (tasa de aprendizaje, número de capas, etc.) y que se documentó el método de ajuste (random search, grid search, etc.).
 - Validación: Entregar al cliente un resumen de configuración por modelo y una explicación del proceso de optimización. El cliente valida que esa información es suficiente para replicar el experimento.
- Req #7: Confección del informe de avance de resultados.

- Verificación: Evaluar que el informe incluya las secciones requeridas (objetivos, metodología, resultados parciales, problemas encontrados, próximos pasos) y esté en el formato establecido.
- Validación: Enviar el informe al cliente y recibir devolución positiva respecto a su claridad, estructura y utilidad como seguimiento del proyecto.
- Req #8: Estudio de al menos 3 artículos sobre los fundamentos de PINN, PINO y la implementación de capas de Fourier.
 - Verificación: Comprobar que el informe bibliográfico contiene referencias relevantes, bien citadas, y un análisis crítico de al menos 3 artículos vinculados a estos temas.
 - Validación: Presentar un resumen ejecutivo al cliente y permitirle revisar el análisis realizado. Validación positiva si el cliente considera que el equipo tiene base teórica suficiente.
- Req #9: Inferencias presentadas en formato gráfico similar al del modelo numérico usado en el organismo.
 - Verificación: Chequear que el código de visualización genera gráficos con la misma estructura, colorimetría y variables que el sistema operativo actual (WRF-SMN).
 - Validación: Mostrar las gráficas al cliente junto a las del modelo tradicional. El cliente debe reconocer la similitud en formato y facilidad de interpretación.
- Req #10: Diseño de arquitectura sin aprendizaje de física.
 - Verificación: Inspeccionar el código y la documentación del modelo para confirmar que no se incorporaron ecuaciones físicas ni restricciones del dominio físico.
 - Validación: Presentar inferencias con y sin incorporación de física al cliente, y confirmar que el comportamiento del modelo es coherente con un sistema puramente estadístico.

15. Procesos de cierre

Para concluir formalmente el desarrollo del proyecto, se llevará a cabo una **reunión final de evaluación** entre responsable y orientadores, en la cual se analizarán los principales aspectos vinculados a la planificación, ejecución y resultados alcanzados. A continuación, se detallan las pautas de trabajo y responsables de cada actividad asociada al cierre:

- **Análisis del cumplimiento del Plan de Proyecto original:**
Se revisarán los objetivos, cronograma, entregables y requerimientos definidos en el plan de proyecto inicial. Esta tarea estará a cargo del Lic. Fabricio Lopretto, quien comparará los compromisos asumidos con los resultados obtenidos, utilizando como insumo principal la documentación generada durante todo el ciclo de vida del proyecto. Se deja la posibilidad abierta a la elaboración de un informe con los desvíos identificados y sus causas.
- **Evaluación de técnicas, procedimientos y resolución de problemas:**
El Lic. Fabricio Lopretto será el encargado de realizar una síntesis crítica sobre las herramientas, metodologías y enfoques empleados, diferenciando cuáles resultaron útiles y cuáles no. También se documentarán los principales problemas surgidos y las soluciones aplicadas. Esta evaluación podrá quedar asentada en un documento técnico que formará parte del cierre documental del proyecto.

■ **Acto de agradecimiento:**

A cargo del Lic. Fabricio Lopretto y jurados. Se dará lugar durante la defensa pública del proyecto final. En esta instancia el proyectista agredecerá a sus directores, a los jurados, a los docentes y no docentes, y al cliente de este proyecto.